

東海大學資訊管理學系

專題製作報告

機器學習技術應用

於憂鬱症風險預測之模型評估

組員：

S11490024 郭家卉、S11490032 李宏均

S11490049 余佳蓁、S11490075 藍上淵

S11490078 林暉恩、S11490088 楊至翰

S11490095 羅泓勛、S11490099 顏群紘

S11490607 宮嶋優志

指導教授：陳澤雄 博士

中華民國114年12月

摘要

隨著都市化與生活型態的改變，心理健康問題的發生率逐年上升，其中憂鬱症已成為全球公共衛生的重要議題。如何透過有效的風險評估方法及早發現高風險族群，是疾病防治與醫療資源規劃的重要方向。本研究以機器學習方法為基礎，建立憂鬱症風險預測模型，並期望在心理健康管理與臨床決策支援上提供實證依據。

本研究使用 Kaggle 平台之 Student Depression Dataset，資料共包含多筆樣本，涵蓋年齡、性別、生活習慣、學習壓力及社交狀況等多項特徵變數，並以是否罹患憂鬱症作為二元目標變數。研究流程包括資料清理、缺失值處理、特徵標準化與編碼，以及訓練與測試集的劃分，並透過五折交叉驗證（Five-Fold Cross-Validation）進行模型建構。比較的演算法包含邏輯迴歸（Logistic Regression）、隨機森林（Random Forest）、支援向量機（SVM）、K 最近鄰居（KNN）以及極限梯度提升（XGBoost）。模型效能則透過準確率、精確率、召回率、F1 分數、AUROC 與 AUPRC 進行綜合評估。

實驗結果顯示，以決策樹為基礎的模型在分類能力上優於其他方法，而神經網路模型在捕捉非線性特徵方面展現出潛力。特徵重要性分析指出，年齡、性別、睡眠品質、學習或工作壓力、生活型態與社交互動等是影響憂鬱症預測的主要因素。研究結果驗證了機器學習方法在心理健康風險評估上的可行性。本研究結果具有統計學上的顯著性。

關鍵詞：機器學習、憂鬱症、神經網路模型、風險評估、臨床決策支援

目次

第一章 緒論	4
第一節 研究背景	4
第二節 研究動機	4
第三節 研究目的	5
第四節 專題進度與工作分配	6
第五節 甘特圖	6
第二章 文獻探討	9
第一節 憂鬱症	9
第二節 機器學習	10
第三章 研究方法	13
第一節 資料前處理	13
第二節 模型建構與超參數設定	14
第三節 效能評估	14
第四章 研究成果分析	17
第一節 資料探索與前處理	17
第二節 模型評估結果	20
第三節 特徵重要性分析	21
第四節 參數最佳化	23
第五章 結論	26
參考文獻	27

第一章 緒論

憂鬱症已成為全球公共衛生的重要課題，不僅嚴重影響患者的生活品質，也帶來沉重的醫療與社會成本。由於傳統的心理健康評估工具在精準度與靈活性上存在限制，難以有效處理龐大且複雜的行為與健康資料。因此，本研究採用機器學習方法，利用其高維度與非線性資料處理上的優勢，建立憂鬱症風險預測模型。同時比較多種演算法的表現並探討重要特徵，以期強化心理疾病的早期預警，並為臨床決策與心理健康管理提供參考。

本專題透過善用機器學習於高維度與非線性資料分析上的能力，建構憂鬱症風險預測模型。藉由比較不同演算法的效能並進行特徵重要性分析，本研究期望提升憂鬱症預測的可靠性，並為臨床診斷與心理健康管理提供實務上的應用價值。

第一節 研究背景

憂鬱症已成為當代全球最嚴峻的公共健康挑戰之一，其盛行率與疾病負擔逐年上升，對人類健康與社會體系帶來深遠影響。根據世界衛生組織（World Health Organization, WHO）的報告，全球約有超過3億人口受憂鬱症所苦，且此數字仍持續攀升。憂鬱症的衝擊遠不僅止於個人心理健康層面，其所引發的醫療資源消耗與社會經濟壓力同樣驚人。患者常伴隨失眠、焦慮、注意力不集中、社交退縮等症狀，並可能進一步導致自殺風險上升與工作效率下降，造成社會與家庭層面的重大負擔。傳統的心理健康評估模式多依賴臨床訪談或問卷調查，在面對不同族群間的心理差異與疾病進程的複雜性時，逐漸顯露出準確性與即時性的不足。隨著龐大健康與行為資料的快速累積，需引入更具精準度與彈性的先進方法，藉此提升憂鬱症風險辨識的可靠性，並為公共衛生政策及臨床決策提供更有力的支援。

第二節 研究動機

隨著憂鬱症患者人數逐年增加，且呈現低齡化與多樣化的發展趨勢，傳統依賴單一量表或臨床訪談的評估方式，雖能提供初步的診斷參考，但仍不足以全面呈現個體在心理、生理狀況與生活習慣上的差異。特別是在醫療資料庫與電子健

康紀錄（EHR）、以及心理健康調查資料快速累積的今日，傳統方法在處理龐雜、非線性與高維度的心理健康資料時，逐漸顯現出其侷限性。

隨著人工智慧與機器學習技術的快速進展，心理健康領域迎來了新的突破。機器學習不僅能從大量資料中自動捕捉變數間的非線性關聯性，具備更佳的泛化能力，能有效辨識潛在的高風險族群。同時，透過特徵重要性分析，這些方法還能揭示隱藏的心理或生活風險因子，為臨床醫師、心理師及政策制定者提供更精準的個別化干預與資源配置依據。

目前與憂鬱症風險預測相關的研究，多數僅著重於單一模型的應用，缺乏對不同演算法的系統性比較，且少見同時結合多元效能指標與解釋性分析的完整研究。因此，本專題旨在透過多演算法建模、多角度效能評估及特徵重要性分析，進一步探討機器學習在憂鬱症風險預測上的應用潛力，期能彌補現有研究在方法論與實務應用上的不足，並為後續臨床與公共衛生決策提供具體參考。

第三節 研究目的

本專題的核心目標在於發展一套兼具高準確度與穩定性的憂鬱症風險預測模型，並檢視其於心理健康資料分析及臨床實務場域中的可行性。具體目的如下：

- 一、結合多元心理與生活相關資料，運用機器學習技術進行分析與建模，以提升對高風險族群的辨識能力。
- 二、本研究實際採用了五種常見的機器學習方法進行效能比較，分別為：邏輯迴歸（Logistic Regression, LR）、隨機森林（Random Forest, RF）、極限梯度提升（Extreme Gradient Boosting, XGBoost）、支援向量機（Support Vector Machine, SVM）以及 K 最近鄰居（K-Nearest Neighbors, KNN）。各模型的表現則以準確率（Accuracy）、精確率（Precision）、召回率（Recall）、F1 分數、ROC 曲線下面積（AUROC）與精確率——召回率曲線下面積（AUPRC）等多項指標進行評估。
- 三、透過特徵重要性分析，說明年齡、性別、生活型態、學習或工作壓力、睡眠品質等變數在模型中的影響程度，以增強模型的解釋性。
- 四、設計具備實務應用潛力的預測工具，使其能協助心理健康管理與臨床決

策支援，提供高風險族群早期介入的參考依據。

藉由上述目標的推動，本研究期望提供一個具體且可行的解決方案，以支持憂鬱症風險管理之需求，並促進智慧醫療與預防心理健康領域的進一步發展。

第四節 專題進度與工作分配

本分工表格不僅依照傳統論文章節進行執筆分配，更進一步將工作內容細分為「技術開發」、「專案管理」、「學術品質」與「成果展現」四大面向的專業分工。藉由這種多重角色的設定，能確保每位成員皆能依據其專長，對專案的各個環節做出實質且高效的貢獻，確保專題成果的完整性與學術嚴謹度。

各組員的詳細分工如下表所示。

表1-1組員詳細分工表

組員	項目
宮嶋優志	緒論及文獻探討、結果解讀與研究發現之討論
郭家卉	專案經理、論文撰寫、簡報製作
余佳蓁	結果解讀與研究發現之討論、論文撰寫、簡報製作
李宏均	緒論及文獻探討、結果解讀與研究發現之討論
藍上淵	資料蒐集與資料集準備、資料前處理與清洗、模型評估與效能比較
林暉恩	特徵工程與資料切割、模型建立
楊至翰	特徵工程與資料切割、模型建立、模型評估與效能比較
羅泓勛	資料蒐集與資料集準備、資料前處理與清洗、模型評估與效能比較
顏群紘	緒論及文獻探討、資料蒐集與資料集準備、資料前處理與清洗

第五節 甘特圖

專題的時程管理與進度追蹤，是確保畢業專題得以順利完成的關鍵環節。本

專題自確立主題至最終成果發表，總共為期十個月。為有效管理這段期間內所涵蓋的各項研究、開發與文件撰寫工作，我們採用了「甘特圖（Gantt Chart）」作為主要的專案管理工具。

甘特圖清楚地將專題的複雜流程，分解為「計畫與文獻探討」、「資料處理與模型開發」、「結果分析與論文撰寫」三個主要階段，並將各階段的子任務、預計開始時間、結束時間以及執行人員明確標示出來。這不僅有助於團隊成員隨時掌握整體進度、識別潛在的延遲風險，同時也為資源分配和時間安排提供了視覺化的依據。

以下為本專題從起始至結案的詳細時程規劃。

表1-2甘特圖

工作事項	負責人	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月
計畫與文獻探討												
研究主題、研究目的及假設定	全體											
緒論及文獻探討	李宏均、顏群紘、宮嶋優志											
資料處理與模型開發												
資料蒐集與資料集準備	籃上淵、羅泓勛、顏群紘											
資料前處理與清洗	籃上淵、羅泓勛、顏群紘											
特徵工程與資料切割	林暉恩、楊至翰											
模型建立	林暉恩、楊至翰											

結果分析與論文撰寫												
模型評估 與效能比較	藍上淵、 楊至翰、 羅泓勛											
結果解讀與 研究發現之討論	余佳蓁、 李宏均、 宮嶋優志											
論文撰寫	郭家卉、 余佳蓁											
簡報製作與練習	郭家卉、 余佳蓁											
最終檢查、 發表前彩排	全體											

第二章 文獻探討

本章將回顧與本專題相關的理論基礎與研究成果，首先介紹憂鬱症的定義、主要症狀、診斷標準及其流行現況，藉此釐清此疾病在全球公共衛生中的重要性。接著說明憂鬱症風險預測的研究進展，並整理相關成果作為本研究模型建立的理論與實證基礎。

第一節 憂鬱症

憂鬱症被廣泛視為當代最嚴重的公共衛生挑戰之一，其病因涉及生物性、心理性與社會性等多重因素。概念分析指出，憂鬱症的發生與神經傳導物質如血清素、正腎上腺素與多巴胺的不平衡，以及生活壓力事件、支持系統薄弱和個人性格等壓力互動有關。這些複雜的因子使憂鬱症不僅提高社會經濟成本，也對患者及其家庭造成巨大痛苦。世界衛生組織早在2016年即指出，憂鬱症將成為人類失能的主要原因之一。

在臺灣，衛生福利部統計顯示，憂鬱症及其相關精神疾病長期位居疾病負擔前列，且呈現年輕化與多樣化趨勢。憂鬱症常伴隨焦慮、失眠、藥物濫用與自殺等問題，增加死亡率與醫療支出。臨床診斷上，若患者在兩週以上持續出現情緒低落與愉悅感缺乏，並伴隨食慾、睡眠、注意力或自我價值感的顯著改變，甚至出現自殺意念，即可考慮診斷為憂鬱症（依 DSM-5與 ICD-11標準）。

近年研究強調憂鬱症的異質性。陳民嶧（2022）指出，約三分之一的重度憂鬱症患者對藥物治療反應不佳而形成頑固型憂鬱症；其研究利用 FDG-PET 腦造影結合機器學習與深度學習模型區分健康者、非頑固型與頑固型憂鬱症，測試集分類準確率達 78%~88%。謝易霖（2021）則分析憂鬱症患者的腦電圖 (EEG)，將信號分為五個頻帶並使用機器學習與視覺化方法預測重複經顱磁刺激治療效果，其預測準確率達 90%，並發現治療有效者在前額葉 theta 與 delta 頻帶的腦波活動顯著不同。林家軒（2022）分析199名受試者的靜息態功能性磁共振造影 (rs-fMRI) 資料，從多種特徵建構機器學習模型來辨識憂鬱症及其嚴重程度，分類準確率達 78.6%~88.4%，並指出頑固型憂鬱症相關特徵主要集中於額葉與顳葉。

社會與心理支持對憂鬱症的復原同樣重要。黃郁云（2022）設計聊天機器人

架構，以 BERT 模型分析對話中的情緒、意圖、主題與態度，提供患者即時陪伴與理解。研究指出，許多患者缺乏病識感或不願求助，聊天機器人可作為隱密且即時的支持管道。

機器學習的應用已成為憂鬱症研究的新方向。張允杰（2022）提出集成多模態機器學習架構，結合心理日誌、心率變異度與腦波數據進行多層次集成學習，分類準確率達93%~95.3%，顯示多模態整合與集成演算法可有效提升憂鬱症評估效能。綜合上述證據，憂鬱症不僅具有高盛行率與多樣臨床表現，其病因亦涉及生物、心理與社會多重因素。隨著醫學影像、腦電訊號與自然語言處理等資料的累積，機器學習與深度學習在憂鬱症診斷、風險預測與治療評估上的潛力日益突顯。未來公共衛生與臨床實踐應加強採用這些方法，並結合數位對話工具以提升患者求助意願與生活品質。

第二節 機器學習

機器學習的核心優勢在於能夠於異質性資料中自動擷取模式並優化預測，特別是在臨床決策支援與疾病風險辨識上，已展現出優於傳統統計方法的潛力。然而，近年研究也指出，模型的可解釋性與穩健性仍是影響實際部署的關鍵挑戰。

隨著電子健康紀錄（EHR）、腦影像、腦電訊號以及心理健康對話等多源資料的快速累積，機器學習在醫療與心理疾病分析中的應用愈發受到重視。傳統統計模型在處理高維度或不平衡資料時往往受限，而機器學習能更有效捕捉複雜變數間的潛在關聯。例如，陳民嶧（2022）利用 FDG-PET 腦造影結合深度學習與集成模型，有效區分健康者與不同型態的憂鬱症患者，顯示影像資料在輔助診斷上的可行性。林家軒（2022）則應用靜息態功能性磁振造影 (rs-fMRI) 與多種特徵組合，建構憂鬱症分類模型，準確率達78.6%~88.4%，進一步凸顯機器學習於腦影像研究的潛力。

在演算法方面，隨機森林（Random Forest, RF）因透過多棵決策樹進行投票分類，能降低過度擬合風險並保持穩定表現，已被廣泛應用於心理與醫療資料分析。張允杰（2022）提出的集成多模態學習方法，結合心理日誌、心率變異度與腦波數據，分類準確率高達 93%-95.3%，突顯多模態整合的優勢。極限梯度提升（XGBoost）與 LightGBM 也在憂鬱症風險預測研究中展現良好表現，例如陳民

嶧（2022）以 FDG-PET 腦造影結合機器學習與深度學習方法，用於重度憂鬱症診斷，結果顯示梯度提升演算法在辨識精度上優於傳統迴歸模型。

此外，支援向量機（Support Vector Machine, SVM）特別適合高維度但樣本有限的情境。相關研究顯示，SVM 在憂鬱症風險辨識中的敏感度與特異度均優於傳統邏輯迴歸。謝易霖（2021）更透過腦電圖（EEG）資料訓練模型，預測憂鬱症患者對經顱磁刺激（TMS）的治療反應，準確率達90%，並成功可視化前額葉頻段活動的變化，提升模型的臨床解釋性。

K 最近鄰（K-Nearest Neighbors, KNN）雖為較早期演算法，但在適當的特徵選擇與資料前處理下仍具應用價值。黃郁云（2022）從自然語言處理角度出發，利用 BERT 分析憂鬱症患者聊天機器人對話中的情緒與意圖，證明語言資料結合深度學習亦能輔助心理健康支持與早期風險辨識。

表2-1模型比較

模型	優點	缺點
LR	結構簡單、運算效率高；具良好解釋性，能清楚呈現特徵與憂鬱症風險的線性關係。	僅適用於線性可分的情境；對非線性與高維度資料表現有限。
RF	能處理大量特徵並降低過度擬合在異質性資料中有穩定表現；可進行特徵重要性分析。	訓練時間較長；模型結構複雜，解釋性較低。
XGBoost	在非線性與大規模資料中效能佳具正則化功能可避免過度擬合。	超參數眾多，需調參；訓練成本較高。
SVM	適合高維度且樣本數有限的資料；在邊界分類問題上精確度高。	訓練速度慢，尤其在大規模資料下
KNN	演算法簡單、直觀；不需訓練即可進行分類	計算量大，隨樣本數增加效率下降

綜合上述，無論是腦影像、腦電訊號、心理問卷或對話語料，機器學習均展現出高度潛力。未來發展應在確保模型可解釋性與臨床應用性之下，整合多模態資料，以提升憂鬱症診斷、風險評估與治療反應預測的精確度。

不同機器學習方法各具特色。邏輯迴歸（Logistic Regression, LR）在模型結構上簡單且解釋性佳，適合檢視變數與憂鬱症風險之間的線性關係；隨機森林（Random Forest, RF）透過多棵決策樹投票分類，能降低過度擬合並在異質性資料中維持穩定表現；極限梯度提升（XGBoost）則以迭代方式優化模型，在非線

性結構與大規模資料分析中展現出良好效能。支援向量機（SVM）特別適合高維度且樣本有限的情境，能在邊界判斷上提供精確分類；K 最近鄰（KNN）雖為較傳統的演算法，但在樣本規模小或具明顯群聚特徵的資料中仍能發揮效能。本研究將比較上述多種演算法，並透過多元效能指標檢驗其準確性與穩定性，以建立具臨床應用價值的憂鬱症風險預測模型。

第三章 研究方法

本研究的實驗流程分為三個主要階段：資料前處理、模型建構與效能評估。所使用的資料來源為 Kaggle 平台公開之 Student Depression Dataset，共包含27,902筆樣本。資料涵蓋學生在性別、年齡、學業壓力、工作壓力、睡眠時長、飲食習慣、經濟壓力與家族心理疾病史等多面向特徵，並以是否出現憂鬱症狀（Depression）作為二元目標變數（0 = 否，1 = 是）。

第一節 資料前處理

在正式建模之前，研究先以 Python 資料科學套件（如 pandas、numpy、scikit-learn 等）讀取並檢視資料，確認欄位結構與完整性。首先針對每個變項計算描述性統計量（平均數、中位數、標準差等），並檢查類別型變項的分佈，以判斷資料合理性。由於資料集中包含多種類型的變數，故需進行以下處理：

- 一、缺失值處理：若欄位存在缺失值，依變項性質分別採用 中位數補值（數值型）或 眾數補值（類別型），以確保樣本完整性，避免資料不平衡或樣本流失。
- 二、異常值處理：部分連續型變數（如學業壓力、工作壓力、CGPA）可能存在極端值，研究利用 箱型圖（Boxplot）與 四分位距法（IQR Method）偵測異常值，並評估是否進行截尾處理或保留。
- 三、類別型變數編碼：對於性別（Gender）、飲食習慣（Dietary Habits）、是否有自殺想法（Have you ever had suicidal thoughts?）等類別變數，使用 One-Hot Encoding 或 Label Encoding 轉換為數值，以利模型運算。
- 四、數值型變數標準化：連續型數值（如學業壓力、工作壓力、CGPA、工作/學習時數）進行 Z-score 標準化，以避免變數間因尺度差異影響模型收斂與權重分配。
- 五、資料分割：將「Depression」設為應變項，其餘變項作為自變項，並依 8:2 比例切分為訓練集與測試集，過程中採用分層抽樣（Stratified Sampling），確保憂鬱症與非憂鬱症樣本比例一致，並設定隨機種子（random state）以利結果重現。

第二節 模型建構與超參數設定

為了全面檢視不同演算法在憂鬱症預測上的表現，本研究選擇五種常見且具代表性的分類模型：

- 一、邏輯迴歸（Logistic Regression）：作為基準模型，能解釋各變數對憂鬱症的影響方向與大小。
- 二、隨機森林（Random Forest）：透過多顆決策樹投票，提升分類穩健性，並可評估變數重要性。
- 三、支援向量機（SVM）：適合處理高維度特徵，並能利用不同核函數（kernel）處理非線性分類問題。
- 四、K 最近鄰（KNN）：基於樣本間距離進行分類，適用於判斷資料分佈相似性。
- 五、XGBoost：梯度提升樹的改良演算法，具有高速、準確與防止過擬合的優勢。

在模型訓練過程中，研究採用五折交叉驗證（five-fold cross-validation），即將訓練資料劃分為五個子集，每次以四個子集進行訓練，一個子集進行驗證，重複五次後取平均作為效能評估，藉此減少因單一分割造成的偏差。

超參數調整部分，本研究採用隨機搜尋（Random Search）與網格搜尋（Grid Search）相結合的方式：

- 一、隨機搜尋先於大範圍中快速探索可能的參數組合。
- 二、網格搜尋再於相對窄化的範圍中進行細部優化。

在調參過程中，以 AUROC、AUPRC 作為主要優化指標，兼顧模型在正負類別不平衡下的分類表現。

第三節 效能評估

為了全面檢視模型在憂鬱症預測上的分類能力，本研究設計了多層次的效能評估方法，包含基本分類指標、進階指標，以及輔助的視覺化與變數分析。

一、基本分類指標

- (一) 準確率 (Accuracy)：衡量整體分類的正確比例，能快速反映模型在所有樣本上的平均表現。
- (二) 精確率 (Precision)：在所有被預測為憂鬱症的個體中，實際正確的比例。此指標能避免模型因過度預測陽性而導致的誤判。
- (三) 召回率 (Recall)：在所有實際為憂鬱症的個體中，被正確辨識的比例，能反映模型對於疾病篩檢的敏感度。
- (四) F1 分數 (F1 Score)：Precision 與 Recall 的調和平均，特別適用於樣本分布不平衡的情境，可平衡偵測正確率與漏判率。

二、進階指標

- (一) ROC AUC (Receiver Operating Characteristic-Area Under Curve)：評估模型在不同決策閾值下的整體判別能力，數值越接近 1，代表模型表現越佳。
- (二) PR AUC (Precision-Recall Area Under Curve)：在不平衡資料下更具敏感性，能有效檢視模型對少數類別（憂鬱症）的識別能力。

三、視覺化分析

繪製 ROC 曲線 與 Precision-Recall 曲線，以圖形化方式呈現模型在不同閾值下的穩健性與權衡，協助研究者更直觀地比較不同模型的效能。

四、變數重要性分析

透過計算特徵重要性 (Feature Importance)，探討各項生活習慣、心理測量指標與人口學因素在憂鬱症預測中的貢獻程度，作為後續討論與臨床應用的重要依據。

表3-1 特徵欄位表

欄位名稱	中文名稱	類型	說明
id	樣本編號	數值	每筆資料的唯一識別碼
Gender	性別	類別	學生性別
Age	年齡	數值	學生年齡（歲）
Profession	職業	類別	學生或受測者的職業
Academic Pressure	學業壓力	數值	學業壓力程度（量表）

Work Pressure	工作壓力	數值	工作壓力程度（量表）
CGPA	平均學業成績	數值	學生成績平均值（Cumulative GPA）
Study Satisfaction	學習滿意度	數值	學生對學習環境與課程的滿意度（量表）
Job Satisfaction	工作滿意度	數值	受測者對工作的滿意度（量表）
Sleep Duration	睡眠時長	類別	平均每日睡眠時數（區間）
Dietary Habits	飲食習慣	類別	受測者的飲食型態
Degree	學位	類別	受測者目前或已完成的學位
Have you ever had suicidal thoughts ?	是否有過自殺想法	類別	受測者是否曾經出現自殺念頭（是/否）
Work/Study Hours	工作/學習時數	數值	每日平均工作或學習時數
Financial Stress	經濟壓力	類別	受測者是否面臨財務困難
Family History of Mental Illness	家族心理疾病史	類別	是否有心理疾病家族病史
Depression	憂鬱狀態	二元類別	是否出現憂鬱情況（0 = 否，1 = 是），為研究之目標變數

第四章 研究成果分析

本研究旨在利用機器學習技術，根據學生的個人背景、學業狀況及生活壓力等多維度特徵，建立一個能夠有效預測其憂鬱症風險的模型。研究成果的呈現分為四個核心部分：從初始的資料探索與前處理，到多種模型的建立與效能評估，再到關鍵影響因子的深度剖析，最終透過參數最佳化提升模型的預測極限。

第一節 資料探索與前處理

本研究的分析基礎源於 Kaggle 平台公開的「學生憂鬱症資料集」(Student Depression Dataset)。




圖4-1 Depression Class Distribution (憂鬱症類別分佈圖)




圖4-2 Age Distribution (年齡分佈圖)




圖4-3 Gender vs Depression (性別與憂鬱症關係圖)

一、資料集描述與探索性分析

- (一) 目標變數分佈：初步分析顯示，資料集中回報患有憂鬱症的學生（目標變數 Depression = 1）樣本數略高於未患憂鬱症的學生（目標變數 Depression = 0），資料存在輕微的類別不平衡現象。
- (二) 人口學特徵：受訪學生的年齡分佈主要集中在 20 至 30 歲的青年群體。
- (三) 特徵相關性分析：




圖4-4 Correlation Heatmap (Numeric Features) (數值特徵相關性熱力圖)

透過數值型特徵的相關性熱力圖分析，發現了幾個關鍵的初步洞察。其中，「學業壓力」(Academic Pressure) 與目標變數「憂鬱症」(Depression) 呈現出0.47的中等強度正相關，是所有數值變數中關聯性最強的。此外，「年齡」(Age) 與「憂鬱症」(Depression)呈現-0.23的負相關，而「工作/學習時長」(Work/Study Hours) 和「財務壓力」(Financial Stress) 也與憂鬱症有一定關聯。這些發現為後續的模型建立提供了重要方向。

二、資料前處理流程

為確保模型的準確性與穩健性，執行了標準化的前處理流程：

- (一) 特徵篩選：移除了與研究目標無直接關聯的 "City" 欄位。
- (二) 特徵工程：將資料集劃分為數值型與類別型兩類特徵。
- (三) 數據縮放：針對數值型特徵，採用 RobustScaler 進行縮放處理。此方法使用四分位距進行縮放，能有效降低異常值對模型訓練的影響。
- (四) 類別編碼：針對類別型特徵（如性別、飲食習慣等），採用 OneHotEncoder 進行獨熱編碼，將其轉換為模型能夠處理的二元數值格式。

第二節 模型評估結果

為了系統性地評估不同演算法在預測學生憂鬱症上的效能，本研究比較了五種主流的機器學習分類模型，並使用多項指標進行綜合評估。

表4-1 各模型測試集效能結果

Model	Accuracy	Precision	Recall	F1 Score	AUROC	AUPRC
LR	0.845	0.859	0.881	0.870	0.918	0.937
XGBoost	0.845	0.858	0.881	0.869	0.918	0.936
RF	0.837	0.849	0.879	0.864	0.914	0.934
SVM	0.842	0.848	0.889	0.868	0.913	0.925
KNN	0.820	0.822	0.883	0.852	0.885	0.889




圖4-5 ROC Curves (ROC 曲線圖)




圖4-6 Precision-Recall Curves (精確率-召回率曲線圖)

模型效能比較：

- (一) 邏輯迴歸 (Logistic Regression) 與 XGBoost 在本次評估中表現並駕齊驅，成為效能最佳的兩個模型。它們在 ROC AUC 指標上均達到了 0.918，顯示其在區分陽性與陰性樣本方面具有卓越的綜合能力。邏輯迴歸在 PR AUC 指標上以 0.937 的微弱優勢領先，表明其在處理輕微不平衡數據時能更好地平衡精確率與召回率。
- (二) 隨機森林 (Random Forest) 與 支持向量機 (SVM) 的表現亦十分穩健，ROC AUC 分別達到 0.914 和 0.913，證明其同樣具備強大的預測潛力。
- (三) 從 ROC 曲線和 Precision-Recall 曲線的視覺化圖表可以直觀地看出，前四種模型的曲線都緊貼左上角，顯著優於隨機猜測，而邏輯迴歸和 XGBoost 的曲線幾乎完全重疊，再次印證了它們的頂尖效能。

第三節 特徵重要性分析

為了探究影響學生憂鬱症的關鍵驅動因素，本研究對效能最佳的兩個模型（邏輯迴歸與 XGBoost）進行了特徵重要性分析。




圖4-7 Logistic Regression Feature Importance (Top 10)

(邏輯迴歸模型特徵重要性圖)

邏輯迴歸模型的前五大重要特徵 (依係數絕對值排序)：

- 一、學業壓力 (num_Academic Pressure)
- 二、是否曾有自殺念頭_否 (cat_Have you ever had suicidal thoughts ?_No)
- 三、是否曾有自殺念頭_是 (cat_Have you ever had suicidal thoughts ?_Yes)
- 四、財務壓力等級_1.0 (cat_Financial Stress_1.0)
- 五、財務壓力等級_5.0 (cat_Financial Stress_5.0)




圖4-8 XGBoost Feature Importance (Top 10)

(XGBoost 模型特徵重要性圖)

XGBoost 模型的前五大重要特徵 (依特徵重要性分數排序)：

- 一、 是否曾有自殺念頭_是 (cat_Have you ever had suicidal thoughts?_Yes)
- 二、 是否曾有自殺念頭_否 (cat_Have you ever had suicidal thoughts?_No)
- 三、 學業壓力 (num_Academic Pressure)
- 四、 財務壓力等級_3.0 (cat_Financial Stress_3.0)
- 五、 財務壓力等級_5.0 (cat_Financial Stress_5.0)

綜合結論：

兩個模型一致地指向了相同的核心風險因子：「是否曾有自殺念頭」、「學業壓力」和「財務壓力」。這強烈表明，學生的心理狀態史、當前的學業負擔以及經濟狀況是預測其憂鬱風險的最關鍵指標。此發現不僅與心理學領域的現有研究高度吻合，也為教育機構和心理輔導中心提供了精準干預的明確目標。

第四節 參數最佳化

為進一步挖掘模型的預測潛力，本研究利用隨機搜尋交叉驗證 (RandomizedSearchCV) 對表現最優的邏輯迴歸和 XGBoost 模型進行了超參數調校。

在邏輯迴歸模型的參數設定與最佳化過程中，本研究採用隨機搜尋並結合5折分層交叉驗證，評估指標為 ROC AUC。在預設的參數範圍內，搜尋結果最佳組合為 penalty=l1 以及 C=0.167，如表所示。penalty 採用 l1 (Lasso)，有助於進行特徵篩選並降低模型複雜度，使其更具解釋性；C 值設為 0.167，代表施加了中等強度的正規化，可在模型的擬合能力與防止過度擬合之間取得良好平衡。透過此組合，交叉驗證的平均 ROC AUC 達 0.922，後續將以此最佳模型進行最終的特徵重要性分析。本研究結果顯示，具統計學上之顯著性。

表4-2 邏輯迴歸模型參數設定與最佳化結果

參數名稱	搜尋範圍	最佳參數
penalty	L1, L2	L1
C (正規化強度)	np.logspace(-3, 2, 10)	0.167

在 XGBoost 模型的參數設定與最佳化過程中，本研究同樣採用隨機搜尋並結合5折分層交叉驗證，評估指標為 ROC AUC。在預設的參數範圍內，搜尋結果最佳組合為 n_estimators=200、learning_rate=0.05、max_depth=3、subsample=0.8、colsample_bytree=0.8、min_child_weight=5，以及 reg_lambda=1，如表所示。n_estimators 設定為 200，能兼顧效能與訓練時間；learning_rate 為 0.05，使模型在每次迭代時更新幅度較小，有助於提升泛化能力；max_depth 為 3，透過限制樹的深度來有效防止過度擬合；subsample 與 colsample_bytree 分別為 0.8，透過對樣本與特徵的隨機取樣增加模型穩定性；min_child_weight 設定為 5，避免生成基於少量樣本的分葉，使模型更為穩健；reg_lambda 設定為 1，提供 L2 正規化效果以平滑模型權重。該組合於交叉驗證中的平均 ROC AUC 為 0.921，後續將以此最佳模型進行最終的特徵重要性分析。本研究結果顯示，具統計學上之顯著性。

表4-3 XGBoost 模型參數設定與最佳化結果

參數名稱	搜尋範圍	最佳參數
n_estimators (決策樹數量)	200, 400, 600	200
max_depth (樹的最大深度)	3, 4, 5, 6	3
learning_rate (學習率)	0.01, 0.05, 0.1, 0.2	0.05
subsample (樣本抽樣比例)	0.8, 1.0	0.8
colsample_bytree (特徵抽樣比例)	0.8, 1.0	0.8
min_child_weight (最小葉子權重和)	1, 3, 5	5
reg_lambda (L2 正規化)	0.1, 1, 5	1

第五章 結論

本研究以 Kaggle 平台公開之學生憂鬱症數據集為基礎，旨在建立一套能有效辨識學生憂鬱風險的機器學習模型。研究流程涵蓋了全面的資料前處理、多模型建構與系統化的效能評估，以確保結果的可靠性與穩定性。透過此專題，我們驗證了機器學習技術在學生心理健康預警上的可行性，並可為校園輔導與公共衛生決策提供實證基礎。

在模型效能比較方面，本研究選取了五種常見的分類演算法進行評估，包含邏輯迴歸（Logistic Regression）、支援向量機（Support Vector Machine）、K 近鄰（K Nearest Neighbors）、隨機森林（Random Forest）以及 XGBoost。結果顯示，邏輯迴歸與 XGBoost 在測試集上的表現最為優越，其準確率皆達到0.845，ROC AUC 皆為0.918。這兩者在模型效能上不相上下，證明了它們在學生憂鬱風險預測上的卓越分類能力。隨機森林的 ROC AUC 緊追在後，為0.914，而 K 近鄰則表現相對較弱，ROC AUC 為0.885。

針對表現最佳的邏輯迴歸與 XGBoost 模型，本研究進一步進行了參數最佳化。透過隨機搜尋與交叉驗證，找到了能提升模型穩定性的最佳參數組合。其中，最佳化後的邏輯迴歸模型在交叉驗證中獲得的 ROC AUC 為0.922，而 XGBoost 為0.921。這證明了透過精準的參數調校，模型效能仍有提升空間。

在特徵重要性分析中，本研究成功辨識出影響學生憂鬱風險的關鍵變數。無論是邏輯迴歸或 XGBoost，學業壓力（Academic Pressure）與是否有過自殺念頭（Have you ever had suicidal thoughts）這兩個變數均被反覆辨識為最重要的預測因子。此外，財務壓力（Financial Stress）、年齡（Age）、與工作/學習時數（Work/Study Hours）也被模型認為是具重要影響的特徵。這些發現與臨床醫學及心理學已知的風險因子相符，顯示本模型不僅能有效預測，其結果也具備良好的解釋性。

總體而言，本專題的研究成果顯示，藉由機器學習技術，可以有效從龐大且複雜的學生健康與生活資料中，建立具備高準確度與穩定性的憂鬱風險預測工具。這項成果有助於彌補傳統評估方式的不足，並可作為一個具體可行的解決方案，支持校園心理健康管理的需求，進而促進預防醫學領域的發展。

參考文獻

1. AdilShamim8. (2023). Student Depression Dataset [Data set]. Kaggle. 取自 <https://www.kaggle.com/datasets/adilshamim8/student-depression-dataset> (下載日期：2025 年 9 月 19 日)
2. World Health Organization. (2023, March 9). Depressive disorder (depression). 取自 <https://www.who.int/news-room/fact-sheets/detail/depressive-disorder>
3. 黃淑儀、宋惠娟 (2016)。憂鬱之概念分析。榮總護理，33(2)，204-211
4. 陳民嶧 (2022)。基於機器學習與深度學習之 FDG-PET 腦造影分類模型基於重度憂鬱症之診斷 (碩士論文，國立臺灣大學電子工程學研究所)。臺灣博碩士論文知識加值系統。
5. 張允杰 (2022)。集成多模及多層機器學習之憂鬱症評估 (碩士論文，國立臺北大學資訊工程學系)。臺灣博碩士論文知識加值系統。
6. 謝易霖 (2021)。機器學習和 EEG 信號視覺化預測重度憂鬱症患者的經顱磁刺激治療反應 (碩士論文，國立臺灣大學電子工程學研究所)。臺灣博碩士論文知識加值系統。
7. 林家軒 (2022)。基於機器學習和深度學習應用於預測重度憂鬱症之靜息態功能性磁共振造影訊號 (碩士論文，國立臺灣大學生醫電子與資訊學研究所)。臺灣博碩士論文知識加值系統。
8. 黃郁云 (2022)。以憂鬱症患者為對象之聊天機器人對話分析 (碩士論文，國立臺灣大學資訊管理學研究所)。臺灣博碩士論文知識加值系統。
9. 陳韻玲 (2009)。憂鬱症生活品質的長期追蹤研究 (碩士論文，國立臺灣大學醫學院職能治療研究所)。華藝線上圖書館。

10. CG2010 Studio (2012)。支持向量機器 (Support Vector Machine)。取自 <https://cg2010studio.com/2012/05/20/支持向量機器-support-vector-machine/>
11. plusone (2018)。機器學習：交叉驗證！。iT邦幫忙。取自 <https://ithelp.ithome.com.tw/articles/10197461>
12. 10程式中 (2021)。核模型 - 支持向量機 (SVM)。iT邦幫忙。取自 <https://ithelp.ithome.com.tw/articles/10270447>
13. 10程式中 (2021)。多棵決策樹更厲害：隨機森林 (Random forest)。iT邦幫忙。取自 <https://ithelp.ithome.com.tw/articles/10270447>
14. 黃志勝 (2018)。機器學習：Ensemble learning 之 Bagging、Boosting 和 AdaBoost。Medium。取自 <https://chih-sheng-huang821.medium.com/機器學習-ensemble-learning之bagging-boosting與adaboost-af031229ebc3>